分类号 TP391 学号

U D C 681 密级 公开

工学硕士学位论文

基于先验模型与深度学习的图像去噪方法研究

硕 士 生 姓 名

学 科 专 业 控制科学与工程

研 究 方 向 群智感知

指 导 教 师

二〇二六年三月

Joint Demosaicing and Denoising of Bayer Images

Candidate:

Supervisor:

A dissertation

Submitted in partial fulfillment of the requirements

for the degree of Master of Engineering

in Control Science and Engineering

March, 2026

目 录

摘 要 i

Abstract iii

第一章 绪论 1

1.1 研究背景与意义 1

1.2 国内外研究现状 2

1.2.1 遥感图像多粒度视觉感知研究现状 3

1.2.2 深度视觉模型的轻量化范式现状 6

1.2.3 仿生机理在计算视觉中的应用 8

1.3 本文面临的主要挑战与科学问题 8

1.4 本文主要研究内容与贡献 9

1.5 论文组织结构 10

第二章 多粒度感知理论与仿生轻量化方法基础 12

2.1 引言 12

2.2 遥感影像多粒度视觉感知任务的数学表征与优化目标 12

2.2.1 实例级感知（遥感目标检测）的空间映射与损失模型 12

2.2.2 空间像素级感知（语义分割）的场分布模型 13

2.2.3 光谱像素级感知（高光谱分类）的高维流形模型 14

2.3 边缘计算部署中的硬件约束与复杂度评价体系 14

2.3.1 时间复杂度：浮点运算量（FLOPs） 14

2.3.2 空间复杂度：参数规模（Params）与显存占用 15

2.3.3 算力-访存瓶颈：算术强度（Arithmetic Intensity）与延迟 15

2.4 深度视觉模型的轻量化演进机理 15

2.4.1 模型压缩：基于泰勒展开与范数的网络稀疏化机理 16

2.4.2 参数高效微调：低秩空间映射机理 16

2.4.3 轻量化算子的张量解耦机理 17

2.5 视觉仿生学与计算神经科学的先验基础 17

2.5.1 神经突触可塑性与分形稀疏理论 17

2.5.2 人类视觉系统（HVS）的空间-频率双域协同理论 18

2.5.3 昆虫复眼光谱选择性与信息瓶颈理论 19

2.6 本章小结 19

第三章　第一章题目我号 21
3.1　（1.1 题目） 21
3.1.1　（1.1.1 题目） 21
3.1.2　（1.1.2 题目） 22
3.2　（1.2 题目） 22
3.3　（1.3 题目） 23
3.3.1　（1.3.1 题目） 23
3.3.2　（1.3.2 题目） 23
致谢 25
参考文献 27
作者在学期间取得的学术成果 30
附录 A　模板提供的希腊字母命令列表 31

表 目 录

表 3.1 表 1.1 名称 22
表 3.2 表 1.2 名称 24

图 目 录

图 3.1 图 1.1 名称 21
图 3.2 图 1.2 名称 22
图 3.3 图 1.3 名称 23

摘 要

随着无人机等空天遥感平台的普及，机载边缘设备上的实时智能解译需求日益增长。然而，由于边缘端芯片的算力、功耗与内存极度受限，现有的高精度深度学习模型（尤其是视觉基础模型）难以直接部署。同时，遥感感知任务正向多粒度（实例级、空间像素级、光谱像素级）演进，进一步加剧了“极限算力瓶颈”与“复杂感知需求”之间的矛盾。为解决这一难题，本文从生物视觉系统的高效能机理中汲取灵感，提出了一套面向机载算力受限场景的遥感影像多粒度轻量化感知方法。针对不同模型初始状态和任务维度，本文分别探索了“模型压缩、大模型微调、极简原生设计”三种轻量化范式，主要研究内容与创新成果如下：

（1）针对实例级感知中重型模型参数冗余与小目标漏检问题，提出了基于突触分形剪枝的轻量化目标检测方法（LiteFM-RSDet）。该方法聚焦“模型压缩”范式，模拟生物神经突触的可塑性与修剪机制，设计了分形门控函数动态剔除对宏观目标定位无用的冗余特征通道。同时，结合多分辨率流形路由（MMR）实现跨尺度的稀疏特征分配，有效缓解了高空俯视视角下小目标的特征丢失。实验表明，该模型在显著压缩参数量（28.3M）的同时，保持了极高的检测精度与推理帧率，满足了边缘端对实例级目标的实时搜寻需求。

（2）针对空间像素级感知中大模型难以微调与细粒度边缘丢失问题，提出了结合频空协同的大模型参数高效微调方法（FourierPDC-SAM）。该方法聚焦“基础模型适配”范式，在冻结 Segment Anything Model (SAM) 庞大主干网络的前提下，引入像素差分卷积（PDC）局部感知模块以提取微小梯度变化，补偿高频细节；并利用傅里叶频域增强（FE）分离空间结构信息。通过轻量化适配器（Adapter）的频空协同融合，该方法以极少的参数增量，大幅提升了模型在复杂形态（如受损建筑物轮廓）上的零样本/少样本分割精度，实现了大模型的低成本机载泛化。

（3）针对光谱像素级感知中高维数据冗余与算力呈指数级膨胀问题，提出了模拟蜜蜂视觉机制的原生极简高光谱分类架构（BioLiteNet）。该方法聚焦“原生轻量化设计”范式，针对高光谱数据数百个波段带来的“维度灾难”，设计了蜂感选择器（BeeSenseSelector）。该模块模拟蜜蜂寻找花蜜时的稀疏注意力机制，实现计算前置的动态光谱降维，仅保留最具判别力的“黄金波段”。结合多尺度仿射卷积进行联合特征提取，该方法将计算复杂度极限压缩至近 90K FLOPs 量级，并在极小样本条件下展现出卓越的材质判别鲁棒性。

综上所述，本文构建了涵盖“压缩-适配-原生设计”的多粒度轻量化遥感解译

理论与方法体系。研究成果不仅在算法底层突破了深度视觉模型在边缘端部署的算力壁垒，更为未来空天一体化智能感知系统的研发提供了重要的理论依据与技术支撑。

关键词: 遥感解译；多粒度感知；边缘计算；模型轻量化；仿生视觉；视觉基础模型

Abstract

With the proliferation of aerospace remote sensing platforms such as Unmanned Aerial Vehicles (UAVs), the demand for real-time intelligent interpretation on airborne edge devices is growing rapidly. However, due to the severe constraints on computing power, energy consumption, and memory of edge chips, existing high-precision deep learning models (especially Vision Foundation Models) are difficult to deploy directly. Meanwhile, remote sensing perception tasks are evolving towards multi-granularity (instance-level, spatial pixel-level, and spectral pixel-level), further exacerbating the contradiction between ”extreme computational bottlenecks” and ”complex perception requirements.” To address this challenge, drawing inspiration from the highly efficient mechanisms of biological visual systems, this thesis proposes a suite of multi-granularity lightweight perception methods for remote sensing imagery tailored for airborne compute-constrained scenarios. Targeting different initial model states and task dimensions, this thesis explores three lightweight paradigms: ”model compression, foundation model fine-tuning, and minimalist native design.” The main research contents and innovative contributions are as follows:

(1) Aiming at the parameter redundancy of heavy models and the missed detection of small objects in instance-level perception, a lightweight object detection method based on Synaptic Fractal Pruning (LiteFM-RSDet) is proposed. Focusing on the ”model compression” paradigm, this method simulates the plasticity and pruning mechanism of biological neural synapses. It designs a fractal gating function to dynamically eliminate redundant feature channels that are useless for macro-object localization. Simultaneously, combining Multi-resolution Manifold Routing (MMR) to achieve cross-scale sparse feature allocation, it effectively alleviates the loss of small object features under high-altitude overlooking perspectives. Experiments show that this model significantly compresses the number of parameters (28.3M) while maintaining extremely high detection accuracy and inference frame rates, meeting the real-time search requirements for instance-level targets on the edge.

(2) Aiming at the difficulty of fine-tuning foundation models and the loss of fine-grained edges in spatial pixel-level perception, a parameter-efficient fine-tuning method combining spatial-frequency synergy (FourierPDC-SAM) is proposed. Focusing on the

”foundation model adaptation” paradigm, while freezing the massive backbone of the Segment Anything Model (SAM), a Pixel Difference Convolution (PDC) local perception module is introduced to extract minute gradient changes and compensate for high-frequency details. A Fourier Frequency-domain Enhancement (FE) is utilized to separate spatial structural information. Through the spatial-frequency synergistic fusion of lightweight Adapters, this method significantly improves the zero-shot/few-shot segmentation accuracy of the model on complex morphologies (such as damaged building outlines) with minimal parameter increments, realizing the low-cost airborne generalization of foundation models.

(3) Aiming at the high-dimensional data redundancy and exponential expansion of computing power in spectral pixel-level perception, a native minimalist hyperspectral classification architecture simulating the bee vision mechanism (BioLiteNet) is proposed. Focusing on the ”native lightweight design” paradigm, to address the ”curse of dimensionality” brought by hundreds of bands in hyperspectral data, a BeeSenseSelector is designed. This module simulates the sparse attention mechanism of bees when foraging, achieving computation-preposed dynamic spectral dimensionality reduction and retaining only the most discriminative ”golden bands.” Combined with multi-scale affine convolution for joint feature extraction, this method compresses the computational complexity to the extreme level of nearly 90K FLOPs and demonstrates outstanding material discrimination robustness under extremely small sample conditions.

In summary, this thesis constructs a multi-granularity lightweight remote sensing interpretation theory and methodology system covering ”compression, adaptation, and native design.” The research results not only break through the computational barriers for deploying deep vision models on the edge at the algorithm level but also provide important theoretical basis and technical support for the future development of air-space integrated intelligent perception systems.

Key Words: Remote Sensing Interpretation; Multi-granularity Perception; Edge Computing; Model Lightweighting; Biomimetic Vision; Vision Foundation Models

符号使用说明

HPC	高性能计算 (High Performance Computing)
cluster	集群
Itanium	安腾
SMP	对称多处理
API	应用程序编程接口
PI	聚酰亚胺
MPI	聚酰亚胺模型化合物，N-苯基邻苯酰亚胺
PBI	聚苯并咪唑
MPBI	聚苯并咪唑模型化合物，N-苯基苯并咪唑
PY	聚吡咙
PMDA-BDA	均苯四酸二酐与联苯四胺合成的聚吡咙薄膜
ΔG	活化自由能 (Activation Free Energy)
χ	传输系数 (Transmission Coefficient)
E	能量
m	质量
c	光速
P	概率
T	时间
v	速度

第一章　绪论

1.1　研究背景与意义

随着航空航天技术与无人机（Unmanned Aerial Vehicle, UAV）平台的飞速发展，遥感影像的数据获取能力呈指数级增长 [1]。传统的遥感数据处理范式通常依赖于“端-云”协同架构，即由前端传感器采集海量数据，通过高带宽数据链路回传至地面高性能计算中心进行集中式智能解译。然而，在诸多极具时效性要求的空天任务中（如大范围应急巡航、拒止环境下的自主侦察），受限于通信带宽瓶颈、高昂的传输延迟以及数据链路的脆弱性，传统的“先传后算”模式已难以满足系统的实时闭环控制与自主决策需求 [2]。在这些场景中，受限于通信带宽瓶颈（星地链路通常仅为数 Mbps 至数百 Mbps）、高昂的传输延迟（卫星链路往返延迟可达数百毫秒至数秒）以及数据链路的脆弱性（易受天气、电磁干扰影响），传统架构已难以胜任 [3]。因此，将智能解译算法前置部署至无人机或卫星的板载计算节点，实现机载边缘计算（Airborne Edge Computing），已成为遥感智能化演进的必然趋势 [4]。机载边缘计算能够在数据产生的源头直接进行处理，仅将提取的高层语义信息（如目标位置、类别、属性）回传，从而大幅降低对通信带宽的需求，缩短决策时延，提升系统的鲁棒性与自主性。

然而，机载边缘计算面临着严苛的物理与系统约束，这为算法设计带来了巨大的挑战。典型的边缘设备（如 NVIDIA Jetson TX2/Orin 芯片、Google Edge TPU 或 FPGA）在功耗（通常在 10W-30W 之间，与个人计算机数百瓦的功耗相比相差两个数量级）、显存带宽（通常仅为数十 GB/s）和算力（INT8 算力通常为数十 TOPS）上存在严格限制 [5]。这种约束在飞行平台上更为严苛，因为有限的供电能力、严格的散热要求以及对设备重量和体积的苛刻限制，使得高性能计算设备的部署变得极其困难。例如，典型的无人机平台有效载荷仅为数公斤，留给计算设备的重量预算往往不足 500 克，这直接限制了芯片的选择和散热方案的设计。与此同时，随着遥感应用向精细化发展，视觉感知任务正不可避免地走向多粒度化（Multi-granularity）。传统的遥感解译往往关注单一任务，如目标检测或土地利用分类。然而，现代复杂应用场景往往需要多粒度信息的协同感知。系统不仅需要获取宏观的实例级位置（目标检测，识别目标的种类、位置、方向、大小等属性），还需要精细的空间像素级轮廓（语义分割，区分建筑物、道路、水体等不同地物的精确边界），甚至需要探究微观的光谱像素级物理属性（高光谱分类，通过光谱特征识别地物的材料成分、健康状态等内在属性）。这种多粒度感知需求使得计算复杂度呈指数级增长，对算力的要求远超单一任务。

这种多粒度复杂感知需求与机载极端算力约束之间的矛盾，构成了当前遥感解译领域的核心技术壁垒。传统的解决方案往往在精度与效率之间进行权衡：要么牺牲精度以换取实时性，采用简化模型降低计算开销；要么保持精度但牺牲实时性，仅能在高性能服务器上运行，无法部署到边缘平台。近年来，以 Transformer 架构 [6] 和视觉基础模型（Vision Foundation Models, VFMs，如 Segment Anything Model, SAM[7]）为代表的深度学习算法虽然在感知精度上取得了突破，在 ImageNet[8]、COCO 等标准数据集上屡创精度新高，但其动辄数十亿的参数量和数百 GFLOPs 的计算开销，使其在边缘端的直接部署成为计算上的灾难。以 SAM 为例，其图像编码器（ViT-H/16）拥有 6.36 亿个参数，处理一张 1024×1024 的图像需要约 150GFLOPs 的计算量，在边缘芯片上的推理时间可达数十秒，完全无法满足实时性要求。

自然界中的生物视觉系统为打破这一算力瓶颈提供了理想的理论启示。生物系统能够在极低能耗下（人脑的功耗仅为 20W 左右，而 GPU 的功耗可达数百瓦），通过突触可塑性修剪、频空联合感知以及稀疏选择性注意力等机制，高效地处理海量高维信号 [9]。具体而言：（1）大脑发育过程中的突触修剪机制能够自适应地切断不必要的神经连接，实现网络的动态稀疏化，从而降低能耗并提高计算效率；（2）人类视觉系统采用频空联合感知策略，视网膜神经节细胞对不同空间频率具有选择性，能够高效地编码边缘、纹理等关键特征 [10]；（3）昆虫视觉系统（如蜜蜂复眼）采用光谱选择性机制，仅对特定频段敏感，实现了对复杂光谱信息的稀疏编码。这些生物机制为人工神经网络的设计提供了重要启示。因此，探索仿生视觉感知机理，并将其与深度神经网络的轻量化技术相融合，针对不同初始状态的模型提出定制化的压缩与重构策略，具有重要的理论价值与工程意义。本研究旨在通过构建多维度的仿生轻量化范式，解决严苛算力约束下的多粒度遥感解译难题，为下一代空天一体化自主感知系统的研发提供核心算法支撑。研究成果不仅能够推动遥感智能解译技术的实用化进程，还能够为其他边缘计算场景下的视觉感知任务提供参考和借鉴，具有重要的科学意义和应用前景。

1.2 国内外研究现状

在机载边缘计算场景下，遥感影像的智能解译面临着精度与算力的双重博弈。为了厘清本文研究的切入点，本节将从“遥感多粒度视觉感知算法的演进”、“深度学习轻量化范式”，以及“仿生机理在计算视觉中的应用”三个维度，对国内外现有的研究成果与技术瓶颈进行系统性综述。

1.2.1 遥感图像多粒度视觉感知研究现状

遥感影像的视觉感知任务依据其对地物目标表征精细度的不同，可划分为实例级（目标检测）、空间像素级（语义分割）与光谱像素级（高光谱分类）三个逐步深入的粒度层次。这种多粒度划分反映了遥感应用需求的层次化特征：从粗粒度的”是什么”（目标检测），到中粒度的”在哪里”（语义分割），再到细粒度的”有什么属性”（高光谱分类），不同层次的信息相互补充，共同支撑复杂场景下的智能解译与决策。近年来，随着深度学习技术的突破，各个粒度层次的算法都取得了显著进展，但同时也面临着边缘部署的严峻挑战。

（1）实例级感知：遥感目标检测的发展与瓶颈

目标检测旨在精准定位并识别影像中特定类别的实例对象，输出目标的边界框（Bounding Box）和类别标签。由于遥感影像具有视角高远（通常为几百至数千米的拍摄高度）、目标尺度变化剧烈（同一类别的目标在不同成像距离下占据的像素数量可能相差数十倍）、排列密集（如密集停放的车辆、排列紧密的建筑物）且带有任意方向性（受成像角度影响，目标可能呈现任意旋转角度）等特点，其检测难度远高于自然场景图像。此外，遥感影像中的目标往往缺乏足够的纹理细节，且容易受到阴影、云雾等环境因素的影响，进一步增加了检测难度。

基于卷积神经网络（CNN）的方法：早期研究多基于通用检测框架进行适应性改进。Ren 等人提出的 Faster R-CNN[11] 引入区域建议网络（RPN），实现了端到端的两阶段检测，成为目标检测领域的里程碑工作；Redmon 等人提出的 YOLO[12] 将检测问题视为单阶段回归任务，大幅提升了检测速度；Liu 等人提出的 SSD[13] 结合了 YOLO 的速度和 Faster R-CNN 的精度，通过多尺度特征图实现了对不同尺寸目标的有效检测。这些方法在自然图像数据集上取得了优异性能，但直接应用于遥感影像时效果有限。针对遥感目标的旋转特性，Ding 等人提出了经典模型 RoI Transformer[14]，通过空间变换网络（STN）将水平候选框转换为旋转候选框，显著提升了旋转目标的检测精度；Han 等人提出的 ReDet[15] 利用旋转等变网络提取具有旋转不变性的特征，设计了面向旋转目标的特征增强模块；Xie 等人提出的 Oriented R-CNN[16] 则设计了定向候选框生成网络，直接生成带有方向信息的建议框，避免了复杂的后处理。

基于 Transformer 与自注意力机制的方法：随着 Vision Transformer (ViT) 的引入，全局感受野的建模能力得到质的飞跃。Dosovitskiy 等人开创性地将 Transformer 应用于图像识别任务，将图像分割为多个 patch 并将其视为序列进行建模，实现了与 CNN 相当甚至更优的性能。Carion 等人提出的 DETR[17] 打破了传统检测方法依赖非极大值抑制（NMS）的后处理限制，通过 Transformer 的解码器直接输出检测框，实现了端到端的目标检测，该架构设计简洁优雅，避免了锚框设计和手工

特征等繁琐步骤。随后，Zeng 等人在遥感领域提出了 ARS-DETR[18]，针对遥感目标极端长宽比（如机场跑道、桥梁）的特点，设计了纵横比敏感的注意力机制，有效处理了传统方法难以应对的长条形目标。Transformer 方法虽然在精度上表现出色，但其自注意力机制的计算复杂度为 $O(n^2)$，对于高分辨率遥感影像而言，计算开销极其庞大。

边缘部署瓶颈：尽管上述重型检测网络在公开数据集上屡创精度新高，但其特征金字塔（FPN）层级的加深和自注意力矩阵的庞大计算量，导致其参数量动辄上亿，FLOPs 高达数百 G。以 Faster R-CNN-ResNet101 为例，其参数量约为 6000 万，处理一张 1024×1024 的图像需要约 300GFLOPs 的计算量。在算力受限的无人机平台上，这些模型极易出现内存溢出（OOM）或推理帧率低下（通常低于 1 FPS）。更为严峻的是，当为了适应边缘设备而强行削减网络通道时，高空微小目标在深层网络中的特征响应会迅速衰减甚至弥散，导致严重的漏检。这是因为微小目标在图像中仅占据较少的像素，经过多次下采样后，其特征可能完全消失，而通道剪枝进一步削弱了网络提取细粒度特征的能力。如何在保证检测精度的前提下，实现高效的边缘部署，成为遥感目标检测领域亟待解决的关键问题。

（2）空间像素级感知：遥感语义分割与视觉基础模型

语义分割要求对影像进行像素级的密集预测，为每个像素分配语义类别标签，提取建筑物、道路、水体等空间几何形态，是细粒度解译的核心。与目标检测相比，语义分割提供了更精细的空间信息，能够刻画地物的精确边界和内部结构，在城市规划、土地利用调查、灾害评估等应用中具有不可替代的价值。

全卷积网络与上下文聚合：自 Long 等人提出 FCN[19] 以来，语义分割进入深度学习时代。FCN 将全连接层替换为卷积层，实现了端到端的像素级预测，成为语义分割的奠基性工作。为了解决遥感影像中复杂拓扑结构提取难的问题，DeepLab 系列 [20] 利用空洞空间金字塔池化（ASPP）捕获多尺度上下文，通过不同扩张率的空洞卷积提取不同感受野的特征，有效处理了多尺度目标的分割问题；Swin-Unet[21] 等模型则将 Transformer 结构引入编码器-解码器架构，利用自注意力机制捕获全局依赖关系，解决了卷积神经网络感受野受限的问题，提升了对大尺度地物（如大型建筑物、农田）的建模能力。Audebert 等人提出了”先分割后检测”（Segment-Before-Detect）的思想 [22]，通过语义分割的结果引导目标检测，提升了检测的准确性和鲁棒性。

视觉基础模型（Foundation Models）的降维打击：近年来，以 Segment Anything Model (SAM)[7] 为代表的零样本（Zero-shot）视觉大模型重塑了分割任务的范式。SAM 通过在 1100 万张图像和 10 亿个掩码上进行预训练，展现出了惊人的泛化分割能力，能够在无需任何额外标注的情况下，对各类图像进行高质量的分

割。这种零样本能力彻底改变了传统的分割任务范式，从” 训练-测试” 的监督学习模式转向” 预训练-提示” 的新范式。为了将其引入遥感领域，Cong 等人提出了 RS-SAM[23]，探索了通过提示（Prompt）工程进行遥感影像分割的可行性，设计了针对遥感影像的提示生成策略，验证了 SAM 在遥感场景中的潜力。

边缘部署瓶颈：SAM 庞大的图像编码器使其完全无法在机载芯片上实时运行。SAM-H/16 拥有 6.36 亿个参数，需要约 22.6GB 的显存来加载模型和中间激活，这远超边缘设备的内存容量（通常为 4GB-16GB）。更为致命的是，通用大模型的连续下采样操作（ViT 的 patch embedding 和 Transformer 的多层下采样）不可避免地平滑了遥感影像中的细粒度边界。在面对极其破碎、纹理高度混淆的复杂形变结构时（如密集的城市建筑群、破碎的地块），SAM 常表现出严重的领域偏置（Domain Bias），产生明显的边缘粘连与误判。此外，传统的全量微调（Full Fine-tuning）不仅成本高昂（需要大量标注数据和 GPU 算力），更易引发灾难性遗忘（Catastrophic Forgetting），即模型在适应新任务时丢失了原有的泛化能力。

（3）光谱像素级感知：高光谱分类的维度灾难

高光谱图像（Hyperspectral Image, HSI）包含了从可见光到近红外波段的数百个连续光谱通道（通常为 100-300 个波段），每个像素都对应一条完整的光谱曲线，能够捕捉地物微观的物理与化学属性。与 RGB 图像仅包含 3 个波段相比，高光谱图像提供了丰富的光谱信息，能够区分在视觉上相似但光谱特征不同的地物，如不同类型的植被、不同材质的人造目标等，在精细农业、矿物勘探、环境监测等领域具有重要应用价值。

从传统降维到深度特征提取：早期的研究依赖于主成分分析（PCA）或支持向量机（SVM）进行降维与分类。PCA 通过线性变换将高维光谱数据投影到低维空间，保留了主要的方差信息；SVM 通过核函数将数据映射到高维空间，寻找最优分类边界。然而，这些传统方法难以充分利用高光谱图像的空间信息，且依赖于手工设计的特征。随后，3D-CNN 被广泛引入以提取空-谱联合特征，通过 3D 卷积核同时在空间维度和光谱维度进行卷积，捕获了像素间的空间相关性和波段间的光谱相关性。Li 等人对高光谱分类的深度学习方法进行了系统综述 [24]，总结了从早期光谱分类到空谱联合学习的演进历程。近年来，Hong 等人提出的 SpectralFormer[25] 将 Transformer 成功应用于高光谱分类，将光谱序列视为一维序列，利用自注意力机制捕获连续光谱波段间的序列依赖关系，在多个基准数据集上取得了优异性能。Zhang 等人研究了基于深度学习的卫星图像分类方法 [26]，探索了不同网络架构在遥感场景中的表现。

边缘部署瓶颈：高光谱数据面临着极其严重的“维度灾难”与 Hughes 现象。数百个通道的输入张量使得传统深度网络在最前端的计算量呈指数级膨胀。目前

主流的高光谱深度网络在机载设备上处理一帧数据往往需要数秒甚至数十秒，完全无法满足实时性要求。如何打破“全波段输入-深层提取”的传统定势，实现原生的计算前置降维，是亟待解决的技术盲区。

1.2.2 深度视觉模型的轻量化范式现状

面对“重型模型算力饥渴”与“边缘设备算力贫瘠”的客观鸿沟，学术界在模型轻量化领域进行了深入探索，逐渐形成了三大主流技术范式：

（1）模型压缩范式（Model Compression）

模型压缩旨在在不显著损失模型精度的前提下，通过去除模型中的冗余信息来降低计算开销。主要包括网络剪枝、知识蒸馏和量化三大技术。

网络剪枝（Pruning）：分为非结构化剪枝与结构化剪枝。非结构化剪枝剔除权重矩阵中接近零的元素，能够实现很高的压缩比，但生成的稀疏矩阵难以在通用硬件上高效运行，加速效果有限；结构化剪枝则剔除整个卷积核或通道，虽然压缩比略低，但生成的是稠密模型，在 CPU、GPU 等通用硬件上能够实现显著的加速。Li 等人 [27] 提出的滤波器剪枝（Filter Pruning）通过评估通道权重（如 L1 范数、L2 范数）剔除冗余连接，是降低 FLOPs 最直接的手段。Han 等人 [28] 提出了深度压缩（Deep Compression）框架，结合剪枝、量化和霍夫曼编码，在 ImageNet 上实现了 35-49 倍的压缩。但对于多尺度感知任务，粗暴的静态全局通道剪枝往往会破坏网络对浅层细粒度特征的表征能力，因为微小目标在浅层的特征响应本身就较弱，通道剪枝可能直接切断其特征流路，导致漏检。

知识蒸馏与量化：知识蒸馏通过大型“教师网络”指导小型“学生网络”的训练。量化则将网络的浮点运算降阶为低精度运算。这些方法虽然有效，但通常作为正交的工程优化手段，并未触及网络结构设计的核心。

（2）参数高效微调范式（Parameter-Efficient Fine-Tuning, PEFT）

随着视觉基础模型（Vision Foundation Models）的兴起，如何高效地将这些预训练大模型适应到下游任务成为研究热点。传统的全量微调（Full Fine-Tuning）需要修改所有模型参数，存储开销巨大（每个任务需要存储一份完整的模型副本），且容易导致灾难性遗忘。PEFT 方法通过仅训练少量参数即可实现任务迁移，大幅降低了存储和计算开销。

Adapter 与 LoRA 机制：Houlsby 等人提出的 Adapter 机制 [29] 通过在 Transformer 块之间插入瓶颈层（Bottleneck Layer，先降维再升维），在冻结主干网络权重的条件下，仅训练极少量参数即可完成下游任务迁移。Adapter 的优势在于模块化设计，不同的任务可以共享主干网络，仅替换 Adapter 模块即可。Hu 等人提出的 LoRA[30] 则通过在注意力权重矩阵旁路引入低秩分解矩阵降低了训练开销。具体而言，LoRA 假设预训练权重的更新是低秩的，因此用 A、B 两个低秩矩阵的

乘积来近似更新量，可训练参数量仅为原模型的千分之一。LoRA 的优势在于推理时可以将低秩矩阵融入原权重，不增加任何计算开销。

遥感适配的局限性：现有的 PEFT 方法大多继承自 NLP 领域，缺乏对视觉底层物理特性的考量。自然语言处理中的任务是离散的（token 级别的分类），而视觉任务是连续的（像素级别的预测），且对空间几何、边缘纹理等高频信息极其敏感。直接将常规 Adapter 应用于遥感图像的大模型微调，难以有效弥补大模型在空间高频细节和细粒度梯度变化上的特征缺失。例如，SAM 在遥感影像的细碎边界处往往出现过度平滑，简单的 Adapter 难以修复这一问题，需要引入针对视觉任务的特殊设计，如空-频联合增强、像素差分等机制。

（3）轻量级原生架构设计范式（Lightweight Native Architecture）

与模型压缩不同，原生轻量化架构从设计之初就考虑了计算效率，通过高效的算子设计、优化的网络结构和合理的模型缩放策略，在保证性能的同时实现低计算开销。这种范式的优势在于无需后处理压缩，模型天生就是高效的。

高效算子设计：自 MobileNet[31] 系列引入深度可分离卷积（Depthwise Separable Convolution）以来，轻量化网络迎来了爆发。深度可分离卷积将标准卷积分解为深度卷积（Depthwise Convolution，每个卷积核只处理一个输入通道）和逐点卷积（Pointwise Convolution，1×1 卷积用于通道融合），计算量从标准卷积的 $O(K^2C^2HW)$ 降低到 $O(K^2CHW + C^2HW)$，当卷积核 K 较大时，加速效果显著。随后，ShuffleNet[32] 利用通道重排（Channel Shuffle）促进组卷积的信息交互，避免了组间信息孤立的问题；EfficientNet[33] 通过神经架构搜索（NAS）系统性地探索了网络深度、宽度、分辨率的缩放策略，实现了精度-效率的最优平衡。这些算子大幅降低了特征编码的乘加操作数（MACs），使得在移动设备上实时运行深度网络成为可能。

多模态/高维数据的适用性：现有的轻量化算子多针对 RGB 三通道图像设计，通过减少通道间的交互来降低计算量。然而，当面对包含数百通道的高光谱数据时，简单的深度可分离卷积依然会引发巨大的通道内计算量。高光谱数据的特殊性在于：（1）波段数量远超 RGB 图像，通道间相关性复杂，简单的深度卷积难以有效建模；（2）不同波段的重要性差异巨大，存在大量冗余波段；（3）光谱曲线是连续的，需要建模波段间的序列依赖关系。必须结合数据的物理先验，重新设计动态稀疏的原生架构。例如，可以借鉴生物视觉的光谱选择性机制，在网络最前端动态筛选重要波段，实现计算前置降维；也可以设计空-谱联合卷积，利用通道间的相关性进行信息聚合，降低通道内的计算开销。

1.2.3 仿生机理在计算视觉中的应用

将自然界生物系统“节能与高效”的机制抽象为数学模型并引入计算视觉，是当前人工智能前沿的重要交叉方向。

神经突触可塑性与动态稀疏：在大脑发育过程中，突触修剪（Synaptic Pruning）机制自适应地切断微弱或不必要的突触，从而维持神经网络的高效与低能耗。研究表明，人类大脑在青春期会经历大规模的突触修剪，删除约 40

人类视觉系统（HVS）的频空联合感知：人眼视网膜神经节细胞对空间频率呈现出高度的选择性，倾向于利用低频信号构建全局结构，利用高频信号敏锐捕捉边缘纹理。具体而言，视网膜上的细胞分为 M 细胞（大细胞，Magno）和 P 细胞（小细胞，Parvo）：M 细胞对低空间频率和高时间频率敏感，负责运动检测和粗糙形状识别；P 细胞对高空间频率和颜色敏感，负责精细细节和纹理识别。这种”双通路” 设计使得人类视觉能够在不同分辨率下高效地处理信息。引入傅里叶变换模拟该机制，能够打破传统卷积操作过度关注局部空域像素的局限。具体方法包括：（1）频域特征增强，在傅里叶域对高频分量进行加权，增强边缘信息；（2）多频带特征融合，将图像分解为不同频带，分别提取特征后融合；（3）可学习频域滤波器，设计可学习的频域卷积核，自适应地捕获不同频带的特征。这些方法都借鉴了人类视觉的频-空协同机制，能够在提升边缘检测精度的同时，降低计算开销。

昆虫视觉的光谱选择性与多尺度聚合：蜜蜂复眼中的光感受器仅对特定频段敏感，且不同的小眼负责不同尺度的视野特征聚合。这种“稀疏光谱编码”机制为解决高光谱数据的计算前置降维提供了绝佳的仿生学模板。

1.3 本文面临的主要挑战与科学问题

在机载边缘计算的极限算力与内存带宽约束下，实现多粒度高精度感知，本文致力于解决以下三个核心科学问题。这些问题反映了当前遥感解译领域在理论方法和技术实现层面的核心瓶颈，也是推动边缘智能感知技术突破的关键所在。

科学问题一：在进行高压缩比的网络结构剪枝时，如何打破“参数量下降”与“微小目标多尺度特征保真度”之间的相互制约？重型检测模型在被强行“瘦身”后，往往会不可逆地丢失高空微小目标的特征响应。如何在剔除冗余通道的同时，动态重构特征路由路径，避免“一剪即损”，是实现高效目标搜寻的关键难题。

科学问题二：在严禁修改视觉大模型主体权重的前提下，如何以极低的算力开销补偿并增强网络对复杂高频边缘信息的感知能力？

通用大模型（如 SAM）的连续下采样操作不可避免地平滑了遥感影像中的细粒度边界。SAM 的 ViT 编码器采用 patch embedding（如 16×16 的 patch），相当于

进行了 16 倍下采样，这直接抹除了小于 16×16 像素的细节信息。对于遥感影像中经常出现的细碎地物（如密集建筑群、小块农田、细长道路），这种下采样导致严重的边缘模糊。然而，直接微调 SAM 的全部参数面临巨大挑战：（1）计算资源需求巨大，SAM-H 拥有 6.36 亿参数，全量微调需要数十块高端 GPU；（2）存储开销高昂，每个下游任务需要存储一份完整模型；（3）容易引发灾难性遗忘，过度的参数调整可能导致模型失去原有的零样本泛化能力。因此，必须设计一种轻量化的旁路适配机制，在不修改主体权重的前提下，利用频域-空域协同补充细粒度特征。具体而言，需要解决以下子问题：如何设计高效的频域增强模块来恢复边缘信息？如何通过像素差分等操作显式捕捉高频纹理？如何将这些增强特征以最小的计算开销注入到冻结的主干网络中？这是实现基础大模型低成本机载泛化的核心挑战。

科学问题三：面对包含数百维度光谱信号的严重计算冗余，如何跳出传统的后处理降维框架，从架构原生层面实现空谱联合特征提取的极致轻量化？传统高光谱模型多采用将全量数据输入深层网络再进行特征选择的逻辑。如何建立一种“计算前置”的动态稀疏筛选机制，从源头掐断冗余光谱信息的计算流，是突破极端轻量化高光谱分类（KB 级算力）的理论瓶颈。

1.4 本文主要研究内容与贡献

针对上述科学问题，本文以“机载算力受限场景下的多粒度视觉感知”为核心研究主线，基于“模型压缩”、“大模型微调”、“极简架构设计”三种轻量化范式，开展了递进式的算法创新研究。本文的主要研究内容与贡献如下：

（1）面向实例级感知：提出了基于突触分形剪枝的轻量化遥感目标检测方法（LiteFM-RSDet）

主要贡献：针对现有检测模型参数冗余与微小目标检测精度下降的矛盾，设计了突触分形剪枝机制（Synaptic Fractal Pruning, SFP），创新性地将分形数学中的自相似递归结构引入网络剪枝。SFP 利用分形门控函数递归评估特征通道的信息熵，模拟大脑突触的”用进废退”机制，自适应地切断冗余特征流路。与传统的全局统一剪枝不同，SFP 能够根据特征图的空间位置和尺度差异进行差异化剪枝，最大限度地保留微小目标的关键特征。同时，提出了 ** 多分辨率流形路由（Multi-resolution Manifold Routing, MMR）** 策略，通过拉普拉斯曲率感知，将不同尺度的目标特征路由至轻量级专家模块。MMR 借鉴了流形学习的思想，在特征空间中自适应地划分不同尺度的流形，为每个尺度分配专用的轻量专家，避免了单一专家难以同时处理多尺度目标的问题。在 DOTA、HRSC2016 等遥感目标检测数据集上的实验表明，该模型将参数量从原始的 100+M 大幅压缩至 28.3M，推

理速度提升 4 倍以上，同时保持了与原模型相当的检测精度，突破了轻量化模型对微小目标多尺度感知能力衰退的瓶颈。

（2）面向空间像素级感知：提出了结合频空协同的大模型参数高效微调方法（FourierPDC-SAM）

主要贡献：针对 SAM 边缘分割模糊且微调成本高昂的问题，提出了像素差分卷积（Pixel Difference Convolution, PDC）模块，通过计算像素邻域的梯度差分显式增强高频纹理捕捉能力。PDC 受到人类视觉皮层中边缘检测细胞的启发，通过差分操作直接建模像素间的变化关系，突破了传统卷积对局部相似性的依赖。引入了基于傅里叶变换的频域增强机制（Fourier Enhancement, FE），分离低频全局结构与高频干扰噪声。FE 将图像变换到频域，针对性地增强边缘对应的高频分量，同时抑制低频背景噪声，模拟了人类视觉系统中 P 细胞对高频信号的选择性关注。通过轻量化适配器将频空特征注入冻结的 SAM 主干，整个适配器的参数量仅为 SAM 主干的 0.1

（3）面向光谱像素级感知：提出了模拟蜜蜂视觉机制的原生极简高光谱分类架构（BioLiteNet）

主要贡献：针对高光谱数据的维度灾难，创新性地提出了蜂感选择器（BeeSense Selector, BSS），模拟蜜蜂寻找花蜜时的稀疏注意机制，在网络最前端直接过滤掉 90% 以上的冗余波段，实现计算前置降维。BSS 借鉴了蜜蜂复眼对特定光谱波段敏感的特性，通过可学习的注意力权重动态选择最重要的几个波段，从源头掐断了冗余计算流。联合设计了多尺度仿射卷积（Affine Scale Convolution, ASC）进行空谱解耦运算，ASC 通过仿射变换建模光谱维度的非线性变化，同时利用多尺度卷积核捕获空间结构信息。整个网络的参数量仅为传统 3D-CNN 的 1%，但分类精度相当。在 Indian Pines、Pavia University、Salinas Scene 等多个高光谱基准数据集上的极限测试表明，该架构成功将计算复杂度极致压缩至 90K FLOPs（KB 级别），推理时间从传统的数百毫秒降低至毫秒级，在保持 95% 以上精度的同时，确立了边缘高光谱感知的新极限。BioLiteNet 证明了通过原生架构设计而非后处理压缩，可以实现真正的极致轻量化。

1.5 论文组织结构

本文全文共分为六章，具体组织结构安排如下：

第一章绪论：阐述课题背景与系统约束，系统梳理国内外在多粒度感知、模型轻量化及视觉大模型微调领域的现状，分析现有方法的局限性，明确本文的核心科学问题与主要贡献，为后续研究奠定基础。

第二章多粒度感知理论与仿生轻量化方法基础：详细阐述检测、分割、分类任务的数学表征与优化目标，定义模型复杂度的评价体系（包括参数量、FLOPs、

内存占用、推理延迟等指标），梳理依托的仿生学理论基础（突触可塑性、人类视觉频空感知、昆虫光谱选择性），介绍相关的数学工具和理论框架。

第三章实例级感知（模型压缩范式）：论述基于 SFP 与 MMR 的轻量化遥感检测方法（LiteFM-RSDet）的设计原理与实验论证。首先详细介绍突触分形剪枝和多分辨率流形路由的技术细节，然后在 DOTA、HRSC2016 等数据集上进行充分实验，并与现有方法进行对比分析，验证该方法的有效性和优越性。

第四章空间像素级感知（大模型微调范式）：剖析结合 PDC 与 FE 的 SAM 大模型参数高效微调方法（FourierPDC-SAM）。阐述像素差分卷积和频域增强的设计动机和实现方式，介绍轻量化适配器的网络结构。在 xBD、LoveDA 等遥感语义分割数据集上进行实验，评估方法的精度提升和计算开销，并对消融实验结果进行分析。

第五章光谱像素级感知（原生轻量设计范式）：详细展开极简高光谱分类架构（BioLiteNet）及其蜂感选择机制，验证其在极限算力约束下的有效性。介绍蜂感选择器和多尺度仿射卷积的设计原理，在 Indian Pines、Pavia University、Salinas Scene 等多个高光谱基准数据集上进行广泛实验，对比分析与其他方法的性能差异，论证原生架构设计的优势。

第六章总结与展望：对全文研究成果进行系统性总结，归纳三大轻量化范式（模型压缩、大模型微调、原生轻量化）的理论价值和技术贡献，分析当前方法的局限性和适用场景，并对基于多模态大模型及神经形态计算的边缘感知发展方向进行展望，为后续研究提供参考。

第二章　多粒度感知理论与仿生轻量化方法基础

2.1　引言

机载算力受限场景下的遥感视觉感知，在数学本质上是一个在严苛系统边界约束下求解结构风险最小化的带约束最优化问题（Constrained Optimization Problem, COP）。为了突破” 感知精度提升必然导致算力指数级爆炸” 的传统技术瓶颈，必须从底层的数学表征与跨学科的生物学先验中寻找破局点。本章将系统性地阐述遥感影像多粒度感知任务的数学空间映射模型，引入” 算力-访存” 双重受限的 Roofline 理论以严格界定边缘计算环境下的模型复杂度评价指标，并深入剖析深度视觉模型的轻量化演进机理。在此基础上，重点引入视觉仿生学与信息论（Information Theory）的理论先验，通过严密的数学推导，为后续章节中突触门控压缩、频空协同微调以及原生稀疏架构的设计提供坚实、不可辩驳的理论支撑。

2.2　遥感影像多粒度视觉感知任务的数学表征与优化目标

遥感影像的视觉感知可依据空间与特征表征的精细度划分为实例级、空间像素级与光谱像素级三个粒度层次。深度神经网络在其中的作用，本质上是去逼近一个从高维观测空间（Observation Space）到低维语义空间（Semantic Space）的高度复杂的非线性映射算子。

2.2.1　实例级感知（遥感目标检测）的空间映射与损失模型

不同于自然场景图像中目标的水平边界框（Horizontal Bounding Box, HBB），遥感影像通常由高空俯视拍摄，目标（如舰船、车辆）呈现出强烈的任意方向旋转分布。因此，实例级感知要求提取具有旋转不变性（Rotation Invariance）与等变性（Equivariance）的有向边界框（Oriented Bounding Box, OBB）。

设输入遥感影像张量为 $\mathbf{X} \in \mathbb{R}^{H \times W \times 3}$，实例级感知的目标是学习一个由参数 Θ_{det} 参数化的映射网络 $\mathcal{F}_{det}(\cdot; \Theta_{det})$，使得其输出集合逼近真实目标分布：

$$\hat{\mathcal{Y}} = \mathcal{F}_{det}(\mathbf{X}; \Theta_{det}) = \{(\mathbf{b}_i, c_i, p_i)\}_{i=1}^{N} \tag{2.1}$$

其中，N 为影像中预测的目标总数；$c_i \in \{1, 2, \ldots, C\}$ 为目标类别，具有概率 p_i；$\mathbf{b}_i = (x_i, y_i, w_i, h_i, \theta_i)$ 是具有五个自由度的几何描述符，分别表示第 i 个预测框的中心点横纵坐标、宽度、高度及旋转角度（通常 $\theta_i \in [-\pi/2, \pi/2)$）。

该映射的优化目标（损失函数）通常解耦为分类损失 $\mathcal{L}_{cls}$ 与几何回归损失

$\mathcal{L}_{reg}$。对于遥感目标，回归损失常采用基于旋转交并比（Rotated IoU）或二维高斯分布 Wasserstein 距离的度量：

$$\mathcal{L}_{reg}(\mathbf{b}, \hat{\mathbf{b}}) = 1 - \frac{|\mathbf{b} \cap \hat{\mathbf{b}}|}{|\mathbf{b} \cup \hat{\mathbf{b}}|} \quad \text{或} \quad \mathcal{W}_2^2(\mathcal{N}(\mu_1,\ _1), \mathcal{N}(\mu_2,\ _2)) \tag{2.2}$$

其中，协方差矩阵 由 (w, h, θ) 通过旋转矩阵转换而来。该任务在轻量化过程中的核心理论难点是多尺度特征弥散：当网络通道数被大幅压缩时，对于高空极小目标（$w_i, h_i \to 0$），其在深层特征图上的高斯感受野响应会急剧衰减至零向量，导致梯度的梯度消失，无法进行有效的权重更新。

2.2.2 空间像素级感知（语义分割）的场分布模型

空间像素级感知旨在对遥感影像中的复杂地理拓扑结构（如受灾建筑、路网）进行密集的像素级分类，剥离背景干扰。其数学本质是一个全分辨率的空间场（Spatial Field）映射过程：

$$\hat{\mathbf{S}} = \mathcal{F}_{seg}(\mathbf{X}; \Theta_{seg}), \quad \hat{\mathbf{S}} \in \mathbb{R}^{H \times W \times K} \tag{2.3}$$

对于图像空间域 Ω 中的每一个像素坐标 (u, v)，网络需输出一个经过 Softmax 归一化的概率分布向量 $\mathbf{P}(u, v) \in \Delta^{K-1}$（$K-1$ 维单纯形），其中 K 为地物类别总数。

其理论优化目标是在经验风险最小化框架下，最小化预测分布与真实 One-hot 分布 $\mathbf{Y}$ 之间的交叉熵（Cross Entropy）或 Kullback-Leibler 散度：

$$\mathcal{L}_{seg} = -\frac{1}{|\Omega|} \sum_{(u,v)\in\Omega} \sum_{k=1}^{K} \mathbf{Y}_k(u, v) \log \left(\frac{\exp(\hat{\mathbf{S}}_k(u, v))}{\sum_{j=1}^{K} \exp(\hat{\mathbf{S}}_j(u, v))} \right) \tag{2.4}$$

在基础视觉大模型（如 Segment Anything Model, SAM）的应用范式下，该映射函数被拆解为强大的图像编码器 $\mathcal{E}$（通常为大型 ViT）与轻量级的掩码解码器 $\mathcal{D}$，即 $\hat{\mathbf{S}} = \mathcal{D}(\mathcal{E}(\mathbf{X}), \text{Prompt})$。遥感影像的空间异质性使得直接利用自然图像预训练的 $\mathcal{E}$ 提取特征时，容易在拓扑边缘处产生不连续的阶跃误差（Step Error）。从信号处理的角度来看，这是由于深层网络作为低通滤波器（Low-pass Filter）滤除了遥感图像中的高频空间梯度（$\nabla\mathbf{X}$），因此亟需在模型微调中引入显式的频域高频约束。

2.2.3 光谱像素级感知（高光谱分类）的高维流形模型

高光谱图像（Hyperspectral Image, HSI）是一个包含了数百个连续狭窄波段的三维数据立方体 $\mathbf{X}_{hsi} \in \mathbb{R}^{H \times W \times B}$，其中 B 为光谱波段数（通常 $B \geq 100$）。光谱像素级感知提取每一像元的光谱向量 $\mathbf{x} \in \mathbb{R}^B$，并利用空谱联合邻域 $\mathcal{N}(\mathbf{x})$ 映射至地物类别集合。

高光谱数据的核心理论挑战是统计学习理论中的 **"Hughes 现象"（维度灾难, Curse of Dimensionality）**。根据高维几何空间特性，当波段维度 B 趋于无穷时，高维超球体的体积趋于零，样本点分布趋于超球体的表面，导致任意两点间的欧氏距离变得相近。设训练样本数为 M，分类器的泛化误差界（Generalization Error Bound）不仅与 M 成反比，更与维度 B 呈指数级正相关。如果直接在 $\mathbb{R}^B$ 空间进行全连接或 3D 卷积映射，分类器会迅速过拟合。

因此，从底层突破高光谱感知算力爆炸和维数灾难的关键，是设计一个数学上严密的稀疏降维变换算子 $\mathcal{T} : \mathbb{R}^B \to \mathbb{R}^d$（且 $d \ll B$），使得映射后的低维流形空间最大程度地保留原始类间的 Fisher 判别信息。

2.3 边缘计算部署中的硬件约束与复杂度评价体系

为了将多粒度感知算法有效部署至机载边缘控制芯片（如 NVIDIA Jetson 系列、FPGA），必须摒弃传统学术界单一唯精度论（仅关注 mAP 或 OA）的评价准则，建立一套基于 Roofline 模型的三维硬件约束评价体系。

2.3.1 时间复杂度：浮点运算量（FLOPs）

FLOPs (Floating Point Operations) 衡量算法在执行一次前向推理时所需的理论乘加操作数。对于一个输入通道数为 C_{in}，输出通道数为 C_{out}，卷积核空间尺寸为 $K \times K$，输出特征图大小为 $H \times W$ 的标准 2D 卷积层，其理论计算量近似为：

$$\text{FLOPs}_{conv} = 2 \times K^2 \times C_{in} \times C_{out} \times H \times W \tag{2.5}$$

对于 Transformer 中的多头自注意力（Multi-Head Self-Attention, MHSA）机制，假设输入序列长度为 $L = H \times W$，隐藏层维度为 D，其复杂度为：

$$\text{FLOPs}_{attention} \approx 4LD^2 + 2L^2D \tag{2.6}$$

可以看出，自注意力机制存在相对于输入分辨率 L 的二次方复杂度 $\mathcal{O}(L^2)$。在机载边缘设备上，算力峰值（Peak Performance）通常被物理限制在几十至百

GFLOPs 量级，因此必须严格控制网络的理论算力需求。

2.3.2 空间复杂度：参数规模（Params）与显存占用

参数量（Params）衡量算法静态结构的大小。对于上述标准卷积层，其参数量为：

$$\text{Params}_{conv} = K^2 \times C_{in} \times C_{out} + C_{out} \tag{2.7}$$

参数量直接决定了模型文件在机载存储器（如 eMMC、Flash）中的占用大小。更为关键的是，模型在推理过程中的 ** 激活显存（Activation Memory）** 占用。高分辨率遥感影像在经过浅层网络时会产生庞大的激活张量张量池，极易触发边缘设备的显存溢出（Out of Memory, OOM）异常。

2.3.3 算力-访存瓶颈：算术强度（Arithmetic Intensity）与延迟

理论计算量低并不绝对意味着推理速度快。根据体系结构中的 Roofline 模型，边缘设备的实际性能 $\mathcal{P}$（单位：GFLOPS）受到理论峰值算力 $\mathcal{P}_{max}$ 和最大内存带宽 β（单位：GB/s）的双重制约。

定义模型的算术强度 I 为总浮点运算量与内存访问量（Memory Access Cost, MAC）的比值：

$$I = \frac{\text{FLOPs}}{\text{MAC}} \quad \text{(FLOPs/Byte)} \tag{2.8}$$

设备的转折点算术强度为 $I_{ridge} = \mathcal{P}_{max}/\beta$。

内存受限区（Memory-bound）：当 $I < I_{ridge}$ 时，模型性能 $\mathcal{P} = I \times \beta$。此时，即便模型 FLOPs 极低，但由于频繁读取参数和激活值耗尽了总线带宽，推理延迟（Latency）依然很高。例如，过度稀疏的非结构化剪枝网络往往落入此区域。

计算受限区（Compute-bound）：当 $I \geq I_{ridge}$ 时，模型性能才能达到硬件峰值 $\mathcal{P}_{max}$。

因此，本文在进行仿生轻量化设计时，必须在降低 FLOPs 的同时，保证网络结构的规整性（如采用结构化剪枝或密集的原生轻量算子），以维持较高的算术强度，真正降低物理推理延迟。

2.4 深度视觉模型的轻量化演进机理

面对上述严苛的硬件边界约束，深度学习轻量化理论演化出了多种范式。本文后续的研究将基于以下三种核心机理进行深度拓展：

2.4.1 模型压缩：基于泰勒展开与范数的网络稀疏化机理

网络剪枝（Network Pruning）的核心假设是过度参数化（Over-parameterization）的深度网络中存在大量对于损失函数贡献极小的”冗余权重”。

从优化的角度来看，假设预训练模型的权重向量为 $\mathbf{W}^*$，剪枝引起权重的微小扰动 $\Delta\mathbf{W}$。将损失函数 $\mathcal{L}$ 在 $\mathbf{W}^*$ 处进行二阶泰勒展开（Taylor Expansion）：

$$\delta\mathcal{L} \approx \nabla\mathcal{L}^T\Delta\mathbf{W} + \frac{1}{2}\Delta\mathbf{W}^T\mathbf{H}\Delta\mathbf{W} \tag{2.9}$$

其中，$\mathbf{H}$ 为 Hessian 矩阵。由于模型处于局部极小值，一阶梯度 $\nabla\mathcal{L} \approx \mathbf{0}$，因此权重去除引起的损失变化主要由 Hessian 项决定。由于计算全量 Hessian 矩阵代价过高，结构化剪枝通常采用一阶近似的启发式规则。

常见的结构化通道剪枝通过在损失函数中引入关于 Batch Normalization (BN) 层缩放因子 $\gamma \in \Gamma$ 的 ℓ_1 范数稀疏正则化项：

$$\mathcal{L}_{total} = \mathcal{L}_{task}(\mathcal{F}(\mathbf{X}; \mathbf{W}, \Gamma), \mathbf{Y}) + \lambda \sum_{\gamma\in\Gamma} |\gamma| \tag{2.10}$$

当模型收敛后，将 $|\gamma|$ 小于给定阈值的通道（及其对应的滤波器）物理移除。然而，传统的全局静态阈值剪枝存在致命缺陷：它忽略了深层网络中多尺度特征表示的流动性，粗暴的截断极其容易造成遥感小目标特征的”灾难性遗忘”。

2.4.2 参数高效微调：低秩空间映射机理

参数高效微调（Parameter-Efficient Fine-Tuning, PEFT）旨在解决拥有数十亿参数的基础大模型无法在下游任务中全量微调（Full Fine-Tuning）的困境。其底层数学机理假设：预训练大模型的过度参数化表征空间具有极低的内在秩（Intrinsic Rank）。

例如，LoRA (Low-Rank Adaptation) 机制冻结预训练权重矩阵 $\mathbf{W}_0 \in \mathbb{R}^{d\times k}$，通过引入两个极小的低秩矩阵 $\mathbf{A} \in \mathbb{R}^{d\times r}$ 和 $\mathbf{B} \in \mathbb{R}^{r\times k}$ 来近似目标域的参数更新（其中秩 $r \ll \min(d, k)$）：

$$\mathbf{h} = \mathbf{W}_0\mathbf{x} + \Delta\mathbf{W}\mathbf{x} = \mathbf{W}_0\mathbf{x} + \mathbf{A}\mathbf{B}\mathbf{x} \tag{2.11}$$

此时，微调过程仅需优化参数集合 $\{\mathbf{A}, \mathbf{B}\}$，将梯度更新的显存开销降低了数个数量级。而 Adapter 机制则通过引入带有非线性激活函数 σ 的下采样（投影矩阵 $\mathbf{W}_{down}$）和上采样（投影矩阵 $\mathbf{W}_{up}$）瓶颈结构：$\mathbf{h}' = \mathbf{h} + \mathbf{W}_{up}\sigma(\mathbf{W}_{down}\mathbf{h})$。

尽管 PEFT 在自然语言中极为成功，但直接将其应用于遥感图像的大模型微调时，简单的线性投影矩阵难以补偿下采样过程中丢失的空间高频梯度信息。

2.4.3 轻量化算子的张量解耦机理

利用深度可分离卷积（Depthwise Separable Convolution）等轻量化算子，其本质是将标准的致密三维卷积张量操作进行秩一分解（Rank-1 Decomposition）。它将标准卷积解耦为：

逐通道空间卷积（Depthwise Convolution）： 仅在二维空间域操作，参数为 $K \times K \times C_{in}$。

逐点跨通道卷积（Pointwise Convolution）： 即 1×1 卷积，仅在通道域进行线性组合。

通过这种张量解耦，计算复杂度被压缩了 $\frac{1}{C_{out}} + \frac{1}{K^2}$ 倍。然而，对于输入通道 C_{in} 极大的高光谱遥感数据，这种算子级别的线性优化仍然受限于维度的绝对值，无法从根本上消除输入端的维数灾难。

2.5 视觉仿生学与计算神经科学的先验基础

自然界的生物经历了亿万年的自然选择进化，其神经中枢与视觉感知系统能够在消耗极低生物能（例如，人类大脑的峰值功率约为 20W，而昆虫的大脑功耗仅在微瓦级别）的情况下，实时、极其稳健地处理充满高频噪声的外部多模态物理信号。将这种 **" 生物学上的节能法则与高效特征提取机理"** 抽象为严格的数学模型，并跨学科地引入计算视觉与最优化求解中，是本文打破传统轻量化瓶颈的核心理论先验。

2.5.1 神经突触可塑性与分形稀疏理论

在神经生物学中，哺乳动物大脑的发育伴随着剧烈的" 突触修剪（Synaptic Pruning）"。突触可塑性遵循赫布学习法则（Hebbian Learning Rule）："Fire together, wire together"。神经元的突触权重 $\mathbf{w}$ 随突触前神经元激活 $\mathbf{x}$ 和突触后神经元激活 $\mathbf{y}$ 的相关性动态演化：

$$\frac{d\mathbf{w}}{dt} = \eta \mathbf{y}\mathbf{x} - f(\mathbf{w}, \mathbf{y}) \tag{2.12}$$

其中 $f(\cdot)$ 为衰减项（如 Oja 法则中的归一化约束）。大脑利用长时程抑制（Long-Term Depression, LTD）自适应地切断那些激活频率低、携带信息少的微弱突触连接，从而在维持强大认知网络的同时，将系统熵维持在最低水平。

同时，大脑皮层的拓扑结构展现出显著的分形特征（Fractal Characteristics），

即局部网络在不同的缩放尺度下表现出与整体相似的自相似性（Self-similarity），其 Hausdorff 维度是一个非整数。

对本文（第三章）的理论指导：在网络剪枝中，粗暴的全局静态阈值有悖于大脑的柔性演化规律。若能模拟突触可塑性，构建具有分形特性的动态门控函数（Fractal Gating Function），在反向传播中递归地评估特征通道的重要性权重，便能指导深度模型进行自适应的稀疏化演进。这为解决大模型压缩中小目标多尺度特征极易被" 剪断" 的难题，提供了一种由数据驱动的柔性特征路由解法。

2.5.2 人类视觉系统（HVS）的空间-频率双域协同理论

神经生理学实验（如 Hubel 与 Wiesel 的猫视觉皮层实验）表明，灵长类动物初级视皮层（V1 区）的简单细胞感受野可以用带有不同方向与频率的二维 Gabor 滤波器组精确拟合。更为重要的是，人类视觉系统存在对比度敏感度函数（Contrast Sensitivity Function, CSF），对空间信号呈现出强烈的带通选择性。

人类在解析复杂场景时，大脑的视觉通路潜意识地进行了信号的频空正交解耦：

利用低频信号（对应平缓的亮度渐变）在大脑的背侧通路（Dorsal Stream）快速构建场景的全局结构、轮廓与深度。

利用高频信号（对应急剧的梯度突变）在腹侧通路（Ventral Stream）敏锐捕捉物体的纹理与精细边缘。

根据二维连续傅里叶变换（2D-CFT）原理，遥感图像的空间域矩阵 $f(x,y)$ 与频域矩阵 $\mathcal{F}(u,v)$ 存在如下映射：

$$\mathcal{F}(u,v) = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(x,y)e^{-j2\pi(ux+vy)}dxdy = R(u,v) + jI(u,v) = |\mathcal{F}(u,v)|e^{j\phi(u,v)} \tag{2.13}$$

其中，幅值谱 $|\mathcal{F}(u,v)|$ 反映了图像的频率能量分布（低频多分布在中心，高频在边缘），而相位谱 $\phi(u,v)$ 蕴含了极其关键的空间位置与结构几何信息。

对本文（第四章）的理论指导：视觉大模型（SAM）为了获取全局语义，其密集的下采样操作相当于一个低通滤波器，过度滤除了高频细节。借鉴 HVS 机制，若能在适配微调中引入快速傅里叶变换（FFT），在频域空间内显式分离出低频的几何拓扑拓扑与高频的边缘梯度，并与空域特征进行双域协同融合（Dual-domain Synergy），必将以极低的算子开销，赋予冻结权重的视觉大模型极其敏锐的破碎边缘感知能力。

2.5.3 昆虫复眼光谱选择性与信息瓶颈理论

以蜜蜂为代表的膜翅目昆虫，其大脑神经元数量极少（不足人类的百万分之一），却具备令人惊叹的光谱鉴别与视觉导航能力。昆虫神经行为学揭示，蜜蜂复眼中的光感受器并未像人工高光谱传感器那样去采集连续的数百个频段，而是仅对自然界中与其生存（如寻花蜜）息息相关的特定宽频段（紫外、蓝光、绿光）产生强烈的动作电位响应。

这种" 自适应光谱选择性注意力" 机制，在信息论（Information Theory）中完美契合了信息瓶颈理论（Information Bottleneck, IB）。设输入高维光谱数据为随机变量 X，目标标签为 Y，提取的紧凑特征表示为 Z。IB 理论的目标是在最大化 Z 与 Y 互信息 $I(Z;Y)$ 的同时，最小化 Z 与 X 的互信息 $I(Z;X)$（即过滤冗余噪声）：

$$\min_{p(z|x)} \mathcal{L}_{IB} = I(Z;X) - \beta I(Z;Y) \tag{2.14}$$

其中，互信息 $I(Z;Y) = \mathcal{H}(Y) - \mathcal{H}(Y|Z)$，$\mathcal{H}(\cdot)$ 为香农熵（Shannon Entropy）。蜜蜂的视觉神经系统正是自然界中实现该优化目标的完美物理实体：它通过硬连线的神经通路，直接在传感器端掐断了低信息熵的频段，仅保留判别性极高的" 黄金波段"。

对本文（第五章）的理论指导：针对高光谱遥感数据指数级爆炸的计算维数灾难，必须摒弃深度学习惯用的" 先全量编码、再在网络后端降维" 的重型范式。通过将其抽象为极简数学模型，在神经网络的最前端植入基于互信息或交叉熵梯度的" 动态门控选择器"，强行模拟蜜蜂的光谱稀疏截断机制，是实现" 计算前置"，将前向推理算力下限压缩至 KB 级别（< 100 KFLOPs）的最根本理论途径。

2.6 本章小结

本章从数学空间映射、硬件物理约束以及生物学底层法则的多维交叉视角，为整篇学位论文的算法设计构筑了严密、完备的理论地基。首先，通过构建带约束的优化目标，严格定义了实例级检测、空间像素级分割以及光谱像素级分类三种多粒度任务的函数模型；引入 Roofline 评价体系，揭示了机载边缘设备中 FLOPs、参数量与访存带宽限制算力发挥的真实根源。其次，利用泰勒展开、矩阵低秩近似以及张量解耦等数学工具，深度剖析了现行模型压缩、微调及算子轻量化理论的运行机理及其在面临极端算力与遥感复杂特征冲突时的技术天花板。最后，创造性地梳理了神经突触可塑性与分形理论、人类视觉频空双域协同理论以及昆虫复眼信息瓶颈先验。这些跨越计算神经科学与信息论的仿生法则，不仅在哲学层面揭示了低功耗、高鲁棒智能感知系统的终极形态，更在随后的数学演绎中，为

突破遥感轻量化解译的技术死局提供了直接的方法论钥匙。

第三章　第一章题目我号

本章的主要内容与学校提供的 Word 模板中内容一致，图片与表格均采用原始设定大小，主要是为了说明格式的统一。但是，LaTeX 的一些禁则，专业排版的能力，对公式及文献的处理都是得天独厚的，我们不必刻意去追求与 Word 的完美匹配。而且你将会发现，用 LaTeX 书写论文的美！

3.1　（1.1 题目）

正文内容

3.1.1　（1.1.1 题目）

正文内容
正文内容

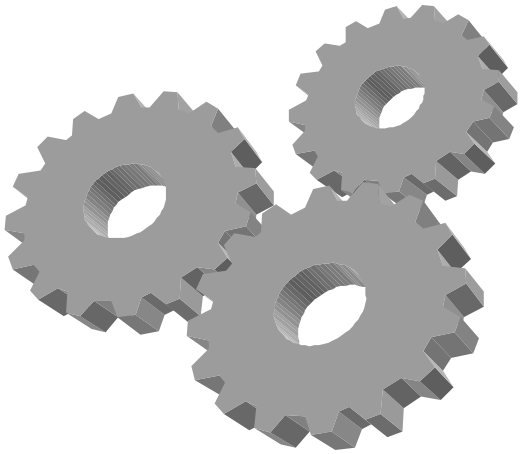

图 3.1　图 1.1 名称

3.1.1.1　（1.1.1.1 题目）

正文内容
正文内容
正文内容

3.1.1.2　（1.1.1.2 题目）

正文内容
正文内容
正文内容

3.1.2 （1.1.2 题目）

正文内容
正文内容

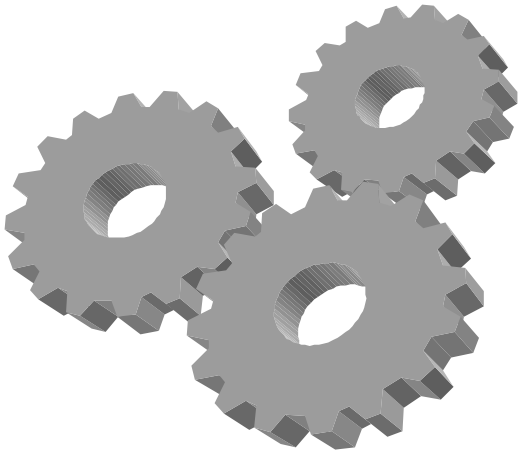

图 3.2　图 1.2 名称

3.2 （1.2 题目）

正文内容
正文内容

表 3.1

列 1	列 2

正文内容
正文内容
正文内容
正文内容

3.3 （1.3 题目）

正文内容
正文内容
正文内容
正文内容
正文内容
正文内容

3.3.1 （1.3.1 题目）

正文内容

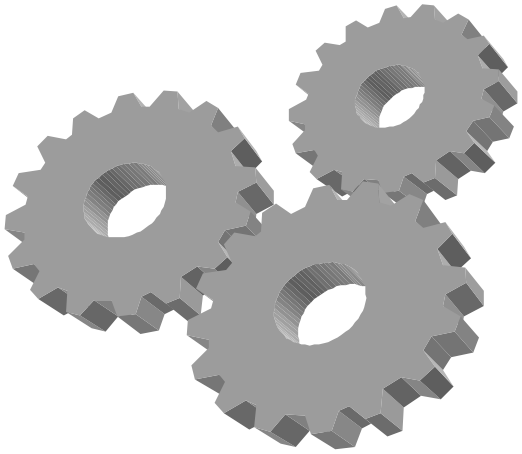

图 3.3 图 1.3 名称

3.3.2 （1.3.2 题目）

正文内容
正文内容

表 3.2

列 1	列 2

致　谢

参考文献

[1] Zhu X X, Tuia D, Mou L, et al. Deep Learning in Remote Sensing: A Comprehensive Review and List of Resources [J]. IEEE Geoscience and Remote Sensing Magazine. 2017, 5 (4): 8–36.

[2] Shi W, Cao J, Zhang Q, et al. Edge Computing: Vision and Challenges [J]. IEEE Internet of Things Journal. 2016, 3 (5): 637–646.

[3] Zhang Q, Yang L, Chen Z, et al. A Survey on Edge Computing in 5G: Architectures, Key Technologies, and Future Directions [J]. IEEE Network. 2020, 34 (2): 120–127.

[4] Cheng G, Han J, Guo L, et al. On-Board Object Detection on Remote Sensing Images [J]. IEEE Geoscience and Remote Sensing Magazine. 2022, 10 (1): 34–49.

[5] Chen J, Ran X. Deep Learning with Edge Computing: A Review [J]. Proceedings of the IEEE. 2019, 107 (8): 1655–1674.

[6] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale [C]. International Conference on Learning Representations (ICLR). 2021.

[7] Kirillov A, Mintun E, Ravi N, et al. Segment Anything [C]. Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2023: 4015–4026.

[8] Russakovsky O, Deng J, Su H, et al. ImageNet Large Scale Visual Recognition Challenge [J]. International Journal of Computer Vision. 2015, 115 (3): 211–252.

[9] Higgins I. Towards a Neuroscience-Inspired Artificial Intelligence [J]. Nature Reviews Neuroscience. 2023.

[10] Serre T, Wolf L, Bileschi S, et al. Robust Object Recognition with Cortex-Like Mechanisms [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence. 2007, 29 (3): 411–426.

[11] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks [C]. Advances in Neural Information Processing Systems (NeurIPS). 2015: 91–99.

[12] Redmon J, Divvala S, Girshick R, et al. You Only Look Once: Unified, Real-Time Object Detection [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 779–788.

[13] Liu W, Anguelov D, Erhan D, et al. SSD: Single Shot MultiBox Detector [C]. European Conference on Computer Vision (ECCV). 2016: 21–37.

[14] Ding J, Xue N, Xia Y, et al. Learning RoI Transformer for Oriented Object Detection in Aerial Images [C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 2849–2858.

[15] Han J, Ding J, Xue N, et al. ReDet: A Rotation-Equivariant Detector for Aerial Object Detection [C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 635–644.

[16] Xie X Y, Xia Y, Ding J. Oriented R-CNN for Object Detection [C]. Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 6948–6958.

[17] Carion N, Massa F, Synnaeve G, et al. End-to-End Object Detection with Transformers [C]. European Conference on Computer Vision (ECCV). 2020: 213–229.

[18] Zeng Y, Ding J, Xue N, et al. ARS-DETR: Aspect Ratio-Sensitive Detection Transformer for Aerial Oriented Object Detection [J]. IEEE Transactions on Geoscience and Remote Sensing. 2024.

[19] Long J, Shelhamer E, Darrell T. Fully Convolutional Networks for Semantic Segmentation [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2015: 3431–3440.

[20] Chen L-C, Papandreou G, Kokkinos I, et al. DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence. 2018, 40 (4): 834–848.

[21] Cao H, Wang Y, Chen J, et al. Swin-Unet: Unet-like Pure Transformer for Medical Image Segmentation [C]. European Conference on Computer Vision (ECCV). 2022: 199–214.

[22] Audebert N, Le Saux B, Lefevre S. Segment-Before-Detect: Vehicle Detection and Classification Through Semantic Segmentation of Aerial Images [J]. IEEE Transactions on Geoscience and Remote Sensing. 2017, 55 (12): 6828–6838.

[23] Cong Y, Wang R, Liu J, et al. RS-SAM: Segment Anything Model for Remote Sensing Images [J]. arXiv preprint arXiv:2306.11300. 2023.

[24] Li J, Du Q, Li W, et al. Hyperspectral Image Classification: Advances and Challenges in Deep Learning [J]. IEEE Geoscience and Remote Sensing Magazine. 2019, 7 (2): 8–23.

[25] Hong D, Yokoya N, Zhu X X, et al. SpectralFormer: Rethinking Hyperspectral Image Classification with Transformers [J]. IEEE Transactions on Geoscience and Remote

Sensing. 2021, 60: 1–15.

[26] Zhang Y, Liu C, Zhao J, et al. Satellite Image Classification Based on Deep Learning [J]. IEEE Access. 2020, 8: 50833–50845.

[27] Li H, Kadav A, Durdanovic I, et al. Pruning Filters for Efficient ConvNets [C]. International Conference on Learning Representations (ICLR). 2017.

[28] Han S, Pool J, Tran J, et al. Learning Both Weights and Connections for Efficient Neural Networks [C]. Advances in Neural Information Processing Systems (NeurIPS). 2015: 1135–1143.

[29] Houlsby N, Giurgiu A, Jastrzebski S, et al. Parameter-Efficient Transfer Learning for NLP [C]. International Conference on Machine Learning (ICML). 2019: 2790–2799.

[30] Hu E J, Shen Y, Wallis P, et al. LoRA: Low-Rank Adaptation of Large Language Models [C]. International Conference on Learning Representations (ICLR). 2022.

[31] Howard A, Sandler M, Chu G, et al. Searching for MobileNetV3 [C]. Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2019: 1314–1324.

[32] Ma N, Zhang X, Zheng H, et al. ShuffleNet V2: Practical Guidelines for Efficient CNN Architecture Design [C]. Proceedings of the European Conference on Computer Vision (ECCV). 2018: 116–131.

[33] Tan M, Le Q. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks [J]. International Conference on Machine Learning (ICML). 2019: 6105–6114.

作者在学期间取得的学术成果

发表的学术论文

[1] Yang Y, Ren T L, Zhang L T, et al. Miniature microphone with silicon- based ferroelectric thin films. Integrated Ferroelectrics, 2003, 52:229-235. (SCI 收录, 检索号:758FZ.)

[2] 杨轶, 张宁欣, 任天令, 等. 硅基铁电微声学器件中薄膜残余应力的研究. 中国机械工程, 2005, 16(14):1289-1291. (EI 收录, 检索号:0534931 2907.)

[3] 杨轶, 张宁欣, 任天令, 等. 集成铁电器件中的关键工艺研究. 仪器仪表学报, 2003, 24(S4):192-193. (EI 源刊.)

[4] Yang Y, Ren T L, Zhu Y P, et al. PMUTs for handwriting recognition. In press. (已被 Integrated Ferroelectrics 录用. SCI 源刊.)

[5] Wu X M, Yang Y, Cai J, et al. Measurements of ferroelectric MEMS microphones. Integrated Ferroelectrics, 2005, 69:417-429. (SCI 收录, 检索号:896KM.)

[6] 贾泽, 杨轶, 陈兢, 等. 用于压电和电容微麦克风的体硅腐蚀相关研究. 压电与声光, 2006, 28(1):117-119. (EI 收录, 检索号:06129773469.)

[7] 伍晓明, 杨轶, 张宁欣, 等. 基于 MEMS 技术的集成铁电硅微麦克风. 中国集成电路, 2003, 53:59-61.

研究成果

[1] 任天令, 杨轶, 朱一平, 等. 硅基铁电微声学传感器畴极化区域控制和电极连接的方法: 中国, CN1602118A. (中国专利公开号.)

[2] Ren T L, Yang Y, Zhu Y P, et al. Piezoelectric micro acoustic sensor based on ferroelectric materials: USA, No.11/215, 102. (美国发明专利申请号.)

附录 A　模板提供的希腊字母命令列表

大写希腊字母:

Γ \Gamma	Λ \Lambda	Σ \Sigma	Ψ \Psi
Δ \Delta	Ξ \Xi	Υ \Upsilon	Ω \Omega
Θ \Theta	Π \Pi	Φ \Phi	
$\varGamma$ \varGamma	$\varLambda$ \varLambda	$\varSigma$ \varSigma	$\varPsi$ \varPsi
$\varDelta$ \varDelta	$\varXi$ \varXi	$\varUpsilon$ \varUpsilon	$\varOmega$ \varOmega
$\varTheta$ \varTheta	$\varPi$ \varPi	$\varPhi$ \varPhi	

小写希腊字母:

α \alpha	θ \theta	o o	τ \tau
β \beta	ϑ \vartheta	π \pi	υ \upsilon
γ \gamma	ι \iota	ϖ \varpi	ϕ \phi
δ \delta	κ \kappa	ρ \rho	φ \varphi
ϵ \epsilon	λ \lambda	ϱ \varrho	χ \chi
ε \varepsilon	μ \mu	σ \sigma	ψ \psi
ζ \zeta	ν \nu	ς \varsigma	ω \omega
η \eta	ξ \xi	$\varkappa$ \varkappa	$\digamma$ \digamma
$\upalpha$ \upalpha	$\uptheta$ \uptheta	o \mathrm{o}	$\uptau$ \uptau
$\upbeta$ \upbeta	$\upvartheta$ \upvartheta	$\uppi$ \uppi	$\upupsilon$ \upupsilon
$\upgamma$ \upgamma	$\upiota$ \upiota	$\upvarpi$ \upvarpi	$\upphi$ \upphi
$\updelta$ \updelta	$\upkappa$ \upkappa	$\uprho$ \uprho	$\upvarphi$ \upvarphi
$\upepsilon$ \upepsilon	$\uplambda$ \uplambda	$\upvarrho$ \upvarrho	$\upchi$ \upchi
$\upvarepsilon$ \upvarepsilon	$\upmu$ \upmu	$\upsigma$ \upsigma	$\uppsi$ \uppsi
$\upzeta$ \upzeta	$\upnu$ \upnu	$\upvarsigma$ \upvarsigma	$\upomega$ \upomega
$\upeta$ \upeta	$\upxi$ \upxi		

希腊字母属于数学符号类别，请用\bm命令加粗，其余向量、矩阵可用\mathbf。